

Lösung: Entscheidungsbäume

DTL.01

Trainingsdaten

Nr	Alter	Einkommen	Bildung	Kandidat
1	≥ 35	hoch	Abitur	O
2	<35	niedrig	Master	O
3	≥ 35	hoch	Bachelor	M
4	≥ 35	niedrig	Abitur	M
5	≥ 35	hoch	Master	O
6	<35	hoch	Bachelor	O
7	<35	niedrig	Abitur	M

Teil A: CAL3 ($S_1=4$, $S_2=0.7$)

CAL3: Knoten darf Blatt werden, wenn

Support ≥ 4 oder Reinheit ≥ 0.7

Attributprüfung

Einkommen:

hoch (1,3,5,6): O=3, M=1 \rightarrow Reinheit = $3/4 = 0.75 \geq 0.7 \rightarrow$ Blatt = O

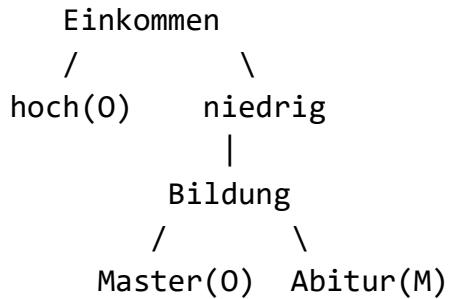
niedrig (2,4,7): O=1, M=2 \rightarrow Reinheit = $1/3 = 0.33 \rightarrow$ weiter splitten

niedrig \Rightarrow Split nach Bildung:

Master \rightarrow (Nr. 2) \rightarrow O \rightarrow vollständig rein

Abitur \rightarrow (Nr. 4,7) \rightarrow M \rightarrow vollständig rein

CAL3-Entscheidungsbaum



Teil B: ID3 (Entropie / Information Gain)

Entropie gesamt

$$O = 4, M = 3$$

$$[H(S) = -4/7 \cdot \log_2(4/7) - 3/7 \cdot \log_2(3/7) \approx 0.9852]$$

Information Gain:

IG(After)

hoch: $H \approx 1.0$

niedrig: $H \approx 0.918$

$$H(\text{Alter}) = 37 \cdot 0.918 + 47 \cdot 1 \quad H(\text{Alter}) \approx 0.964$$

$$\text{Gain}(H, H(\text{Alter})) = 0.9852 - 0.964 \quad \text{Gain}(H, H(\text{Alter})) \approx 0.022$$

IG(Einkommen)

hoch: $H \approx 0.8113$

niedrig: $H \approx 0.9183$

$$[H_{\{\text{split}\}} = 4/7 \cdot 0.8113 + 3/7 \cdot 0.9183 \approx 0.8571]$$

$$[\text{IG}(\text{Einkommen}) = 0.9852 - 0.8571 = 0.1281]$$

IG(Bildung)

Abitur: $H \approx 0.9183$

Master: $H = 0$

Bachelor: $H = 1$

$$[H_{\{\text{split}\}} = 3/7 \cdot 0.9183 + 2/7 \cdot 0 + 2/7 \cdot 1 \approx 0.6793]$$

$$[\text{IG}(\text{Bildung}) = 0.9852 - 0.6793 = 0.3060]$$

→ Bildung bester Split!

Teilbäume

Master → O (rein)

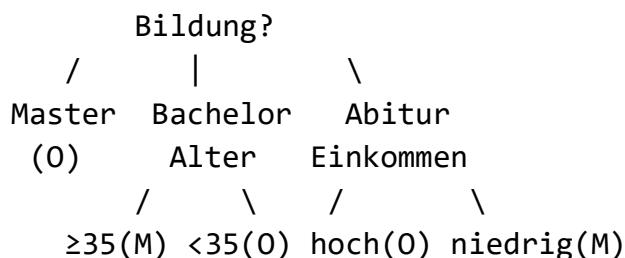
Bachelor (Nr.3,6):

- Alter trennt: $\geq 35 \rightarrow M / < 35 \rightarrow O \rightarrow 2$ reine Blätter

Abitur (Nr.1,4,7):

- Einkommen trennt: hoch → O / niedrig → M

ID3-Entscheidungsbaum



DTL.02

Ausgang: $x_3(x_2(x_1(C,A), x_1(B,A)), x_1(x_2(C,B), A))$

1) Faktorisierung (Distributivität):

$$x_3(x_1(x_2(C,B), A), x_1(x_2(C,B), A))$$

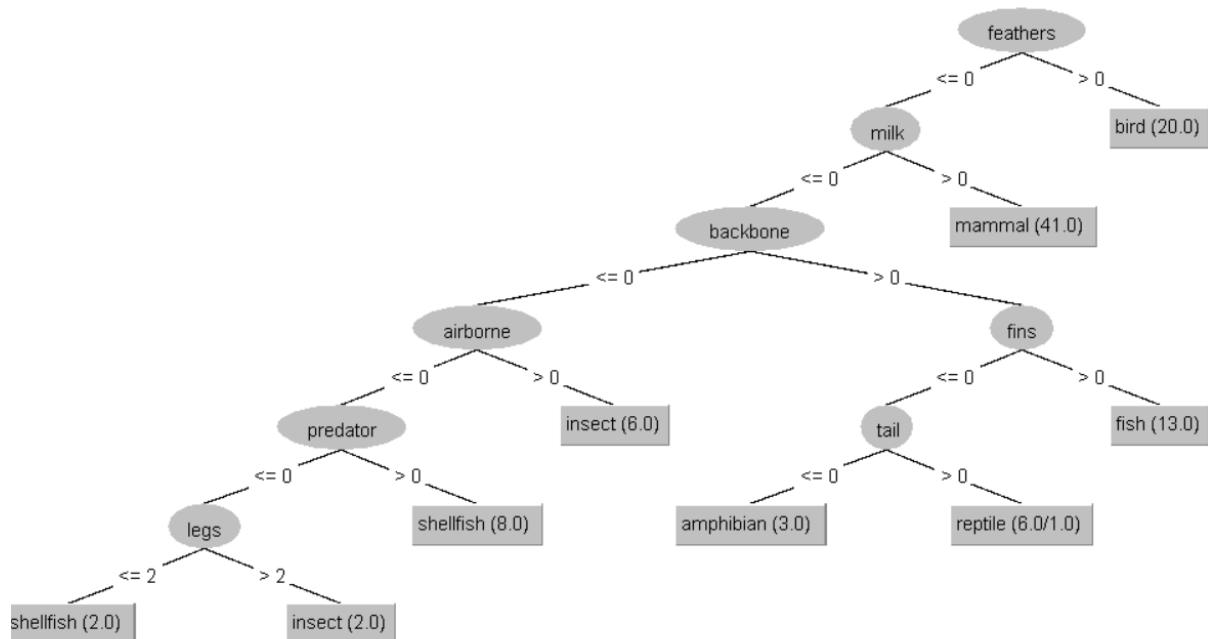
2) Vereinfachung gleichartiger Unterbäume:

$$x_1(x_2(C,B), A)$$

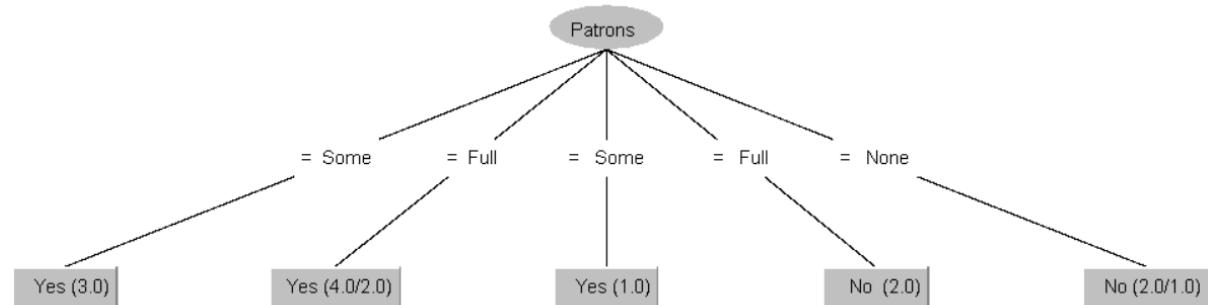
DTL.03

1)

Zoo



Restaurant



Zoo-Datensatz:

- Wichtige Merkmale: Federn, Milch, Rückenmark, Flossen, Schwanz, flugfähig

- Logische Klassifikation: Federn → Vogel, Milch → Säugetier
- Fehlerrate :0.9901 %
- **Confusion Matrix:** fast alle Tiere richtig, nur wenige Verwechslungen bei ähnlichen Klassen (Reptilien ↔ Amphibien, Insekten ↔ Schalentiere)

Restaurant-Datensatz:

- Wichtigstes Merkmal: Patrons (Anzahl Gäste)
 - None → No, Some/Full → Yes
- Fehlerrate :25 %
- **Confusion Matrix:** die meisten Entscheidungen richtig, wenige Yes fälschlicherweise als No

2)

Nominal: Kategorien ohne Reihenfolge

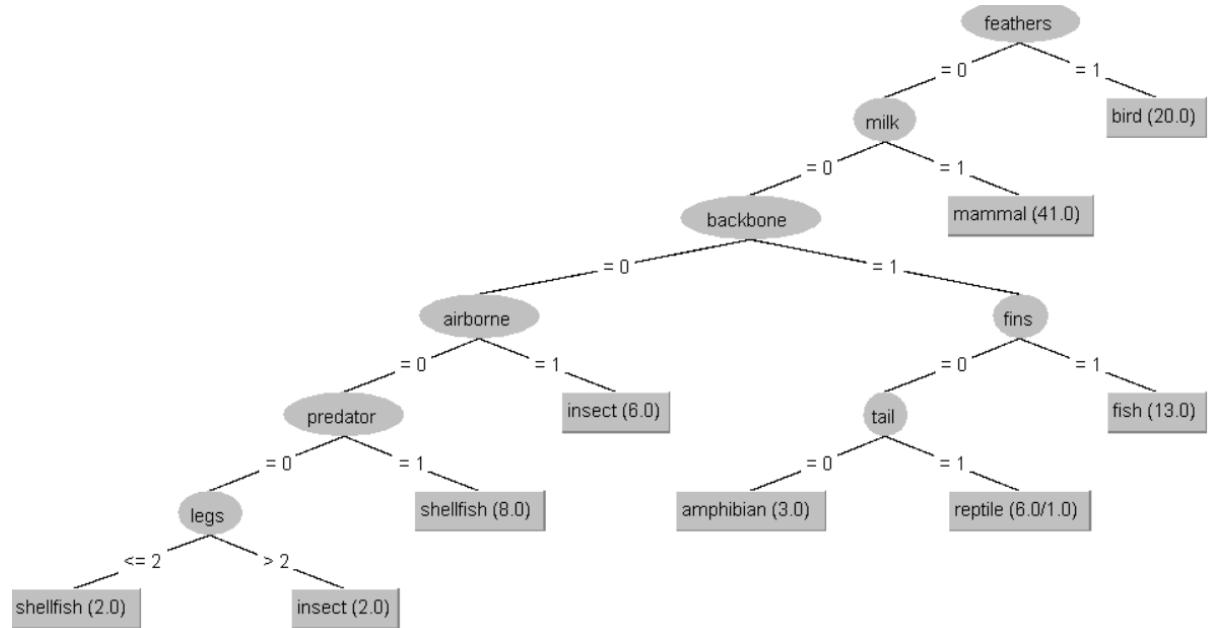
Ordinal/Numeric: Zahlen oder geordnete Kategorien

String: Text/Zeichen, nicht für Berechnung geeignet

3)

Training mit J48

Zoo



Restaurant

